

Collocations Extraction of TBMM Corpus

CSE4095 - Introduction to Language Processing

İlker Fener - 150115024 Diala Jubeh - 150119686 Asem Okby - 150119688 Nurhande Akyüz - 150119933

Associate Professor Dr. Murat Can Ganiz

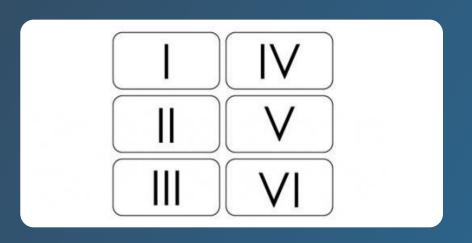
Outline

- Introduction
- Preprocessing The Data
- Collocations Extraction
- Comparison Of Methods
- Summary

Introduction

- Aim of the project
- Describing the dataset
- The produced results

Preprocessing The Data





Collocations Extraction Methods

Collocations By Frequency Mutual Information Hypothesis Testing: T-test

Collocation By Frequency

C(w1;w2)	collocation	tag pattern
15135	"('Büyük', 'Millet')"	AN
11883	 "('Millet', 'Meclisi')" 	NN
10906	 "('soru', 'önergesi')" 	 NN
9785	 "('sıralarından', 'alkışlar')" 	 NN
7968	l "('Meclisi', 'Başkanlığına')" 	 NN
7759	 "('yazılı', 'soru')"	 An
6166	 "('arz', 'ederim')"	NN
6150	 "('Devlet', 'Bakanı')"	 NN
5794	 "('Kabul', 'edenler')" 	 NN
5334	 "('yazılı', 'cevabı')"	 An

Collocation By Frequency

C(w1;w2)	collocation	tag pattern
18189	"('sıralarından', 'alkışlar')"	NN
17993	"('Büyük', 'Millet')"	I An
16761	"('soru', 'önergesi')"	 NN
13162	 "('Millet', 'Meclisi')"	I NN
9978	 "('yazılı', 'soru')"	I An
9381	"('BAŞKAN', 'Teşekkür')"	I An
9217	 "('önergesi', 'Başkanlığa')" 	I NN
9111	 "('değerli', 'milletvekilleri')" 	I An
8976	 "('Türkiye', 'de')" 	I An I
8805	 "('Kabul', 'edenler')"	I NN

Collocation By Frequency

C(w1;w2)	collocation	tag pattern
90229	 "('le', 'ri')"	NN
26526	 "('Baş', 'kan')" 	 NN
25384	 "('me', 'si')"	 NN
25252	 "('BA\$', 'KAN')"	 NN
24955	 "('soru', 'önergesi')" 	 NN
21252	 "('so', 'ru')"	 NN
19452	 "('yazılı', 'soru')" 	 An
19363	 "('ko', 'nu')"	 NN
19116	 "('Kabul', 'edenler')" 	 NN
18576	 "('öner', 'ge')" -	 NN

Collocation By Mutual Information

I(w1;w2)	C(w1)	C(w2)	C(w1;w2)	collocation
14.05182413349557	1178	1202	1178	"('SUHA', 'OKAY')"
13.808325367680274	 1423	1423	 1423	 "('SIRRI', 'SAKIK')"
13.803227605298126	 1427	1377	 1376	 "('KÂTİP', 'ÜYELER')"
13.697143864515985	 1537	1529	1529	l "('BEKİR', 'BOZDAĞ')"
13.658904371971014	 1507	1572	 1501	 "('Mehdi', 'Eker')"
13.541201235215599	1401	1666	1363	 "('NEVZAT', 'KORKMAZ')" '
13.515575918036705	1681	1571	1515	 "('SUAT', 'KILIÇ')"
13.514463241289054	1743	 1178	1177	 "('HAKKI', 'SUHA')"
13.512796558994163	 1708	1361	1331	 "('Ad', 'yaman')"
13.453973342110512	 1498	 1450	 1194	 "('Erkan', 'Akçay')"

Collocation By Mutual Information

I(w1;w2)	C(w1)	C(w2)	C(w1;w2)	collocation
13.826911353605638	1565	1589	1564	"('TABİİ', 'KAYNAKLAR')"
13.761212952888028	1587	 1662	1585	 "('SATAŞMALARA', 'İLİŞKİN')" -
13.749916870930475	1571	 1548	1450	"('Lütfi', 'Baydar')"
13.734437313554585	1639	 1657	1602	"('Mülkiye', 'Birtane')"
13.723622299585225	1707	 1664	1663	"('BEKİR', 'BOZDAĞ')"
13.653132918217107	1789	 1576	1572	"('Kadir', 'Gökmen')"
13.5898199164518	1737	 1696	1572	"('Veysel', 'Eroğlu')"
13.564337007371533	1532	 1885 	1514	"('Ruhsar', 'Demirel')"
13.563135520062849	1909	 1897	1897	"('VELİ', 'AĞBABA')"
13.517706926766607	1844	 1969	1843	"('Nedret', 'Akova')"

Collocation By Mutual Information

I(w1;w2)	C(w1)	C(w2)	C(w1;w2)	collocation
13.66212592790625	8	8 8	8 8	"('Zeynep', 'Altıok')"
13.492200926463937	9	 9	 9	"('Tacettin', 'Bayır')"
13.492200926463937	9	9	 9	"('Dengir', 'Mir')"
13.340197833018886	10	 10	 10	"('ÖZDOĞAN', 'ENÇ')"
13.340197833018886	10	10	 10	"('yazılmıştır', 'İÇİNDEKİLER')"
13.340197833018886	10	10	 10	"('belirtilmiş', 'alıntı')"
13.340197833018886	 10	10	 10	"('Tarihinden', 'İtibaren')"
13.340197833018886	10	10	 10	"('Maddesi', 'Uyarınca')"
13.340197833018886	 10	 10	 10	"('GÖKCEN', 'ÖZDOĞAN')"
13.340197833018886	 10	 10	 10	"('BAŞKANLARININ', 'KONUŞMALARI')"

Collocation By Hypothesis Testing : T - test

t t	C(w1)	C(w2)	 C(w1;w2)	collocation
203.17708536748637	164122	53687	42428	"('Sayın', 'Başkan')"
 176.19650568589998 -	35656	32089	31195	"('sıralarından', 'alkışlar')"
 145.87541517692785	21409	21526	21340	"('AK', 'PARTİ')"
 137.167515305873	32335	22460	18910	"('Teşekkür', 'ederim')"
 135.13933431893773	38144	19499	18360	"('ilişkin', 'açıklaması')"
 133.51450149519994	18834	18596	17872	"('Büyük', 'Millet')"
 132.70648015924584 -	72688	18834	17790	"('Türkiye', 'Büyük')"
 131.99920106300746	92864	164122	19370	"('BAŞKAN', 'Sayın')"
 126.30829865352594 -	37019	17585	16039	"('Kabul', 'edenler')"
 122.63328688995487	92864	32335	15430	"('BAŞKAN', 'Teşekkür')"
 +			 	·

Collocation By Hypothesis Testing : T - test

t	C(w1)	C(w2)	C(w1;w2)	collocation
181.7100913956161	114123	44886 	33804	"('Sayın', 'Başkan')"
175.92705641358512	 35669	 32160	 31127	l "('sıralarından', 'alkışlar')" '
146.44625704675255	 35210	 22404 	 21568	l "('ilişkin', 'açıklaması')" '
146.19729168311767	 21523	 34192 	 21487 	 "('AK', 'PARTİ')"
130.4369755361739	 17075	 17173	 17059	 "('Mikrofon', 'otomatik')"
130.40879111573335	 17173	 17208 	 17052 	l "('otomatik', 'cihaz')"
130.28685017095134	 31534	 17362	 17059 	 "('tarafından', 'kapatıldı')"
130.2283017124624	 17208	 31534 	 17043	 "('cihaz', 'tarafından')"
122.82295497028802	 34192	 35669	 15273	 "('PARTİ', 'sıralarından')"
116.1243610697605	 70584	 114123	 14701	 "('BAŞKAN', 'Sayın')" :

Comparison Of Methods

- Collocation By Frequency
- Collocation By Mutual Information
- Collocation By T- test



All Corpus (All Donems) - Collocation By Frequency

C(w1;w2)	collocation	tag pattern
31127	"('sıralarından', 'alkışlar')"	NN
21568	 "('ilişkin', 'açıklaması')"	NN
17052	 "('otomatik', 'cihaz')"	AN
17043	 "('cihaz', 'tarafından')"	NN
13058	 "('Büyük', 'Millet')"	AN
12071	 "('CHP', 'sıralarından')"	NN
11810	 "('Kanun', 'Teklifi')" 	NN
11438	 "('değerli', 'milletvekilleri')" 	AN
11418	 "('Teşekkür', 'ederim')"	NN
10473	 "('Merkezî', 'Yönetim')"	AN

All Corpus (All Donems) - Mutual Information

663 684 685 1044 922	661 684 685 778 703	"('MÜSAVAT', 'DERVİŞOĞLU')" "('KEMALBAY', 'PEKGÖZEGÜ')" "('SERPİL', 'KEMALBAY')" "('Müsavat', 'Dervişoğlu')" "('Metanet', 'Çulhaoğlu')"
 685 1044	 685 778	 "('SERPİL', 'KEMALBAY')" "('Müsavat', 'Dervişoğlu')"
 	778	 "('Müsavat', 'Dervişoğlu')"
į		i
 922 	 703	 "('Metanet', 'Çulhaoğlu')"
5 1168	765	 "('RUŞTU', 'TİRYAKİ')"
75 661	 661	 "('DURSUN', 'MÜSAVAT')"
19 722	722	 "('YAVUZ', 'AĞIRALİOĞLU')"
 30 2214	2206	"('SARUHAN', 'OLUÇ')"
 55 2342	1 1335	"('Saruhan', 'Oluç')"
	 30 2214 	

All Corpus (All Donems) - Hypothesis Testing : T - test

t	C(w1)	C(w2)	C(w1;w2)	collocation
174 . 91134475405363	193554	167438	31127	"('sıralarından', 'alkışlar')"
172.40712491797947	936663	272166	33804	l "('Sayın', 'Başkan')"
145.89676977194608	125433	97304	21487	 "('AK', 'PARTİ')" '
145.73256584070825	 35 11 93	57109	21568	 "('ilişkin', 'açıklaması')" '
130.4053869332727	56258	57547	17059	 "('Mikrofon', 'otomatik')" '
130.37538924022556	57547	57125	17052	 "('otomatik', 'cihaz')"
130.03143772992468	 172060	53186	17059	 "('tarafından', 'kapatıldı')" '
129.92702396234773	 57125	172060	17043	 "('cihaz', 'tarafından')"
122.32534258536487	97304	193554	15273	 "('PARTİ', 'sıralarından')"
112.84139755960638	 138366	143014	13058	 "('Büyük', 'Millet')"

Summary

- The results found
- What's next?

